# Оценка качества генерации текста LLM с помощью метрик

Трек A: Question Answering

**Модели:** Qwen 3.5 9B (llama.cpp, Q4_K_M) / GPT-4o (OpenAI API)

**Датасет:** SberQuAD, 100 примеров, validation split

**Метрики:** F1, EM, BLEU, Semantic Similarity, Answer Containment

# 1. Методология

Сравнительный анализ двух LLM на задаче extractive QA (SberQuAD, 100 примеров, seed=42). Qwen 3.5 9B запущена локально (llama.cpp, квантизация Q4_K_M, GPU). GPT-4o — через OpenAI API. Оба клиента используют OpenAI-совместимый интерфейс.

Метрики: Token F1 Score, Exact Match, BLEU (effective_order), Semantic Similarity (paraphrase-multilingual-MiniLM-L12-v2), Answer Containment (кастомная). Нормализация: lowercase, удаление пунктуации, max-over-answers.

Проведено 6 экспериментов: zero-shot baseline, few-shot (3 примера), влияние длины контекста, A/B-тест форматов промптов, анализ температуры, классификация ошибок. Статистическая значимость: Wilcoxon, paired t-test, bootstrap 95% CI.

# 2. Zero-Shot vs Few-Shot

| Модель | EM | F1 | BLEU | Sem. Sim. | Время (с) |
|---|---|---|---|---|---|
| Qwen 3.5 9B (ZS) | 0.51 | 0.808 | 0.428 | 0.881 | 0.50 |
| GPT-4o (ZS) | 0.52 | 0.804 | 0.413 | 0.879 | 0.76 |
| Qwen 3.5 9B (FS) | 0.65 | 0.891 | 0.725 | 0.938 | 0.53 |
| GPT-4o (FS) | 0.58 | 0.834 | 0.635 | 0.910 | 0.69 |

В zero-shot режиме модели показывают эквивалентное качество (F1 0.81 vs 0.80). Few-shot даёт прирост обеим: Qwen +0.08 F1, GPT-4o +0.03 F1. Qwen сильнее зависит от демонстрации формата ответа — без примеров склонна к многословным ответам.

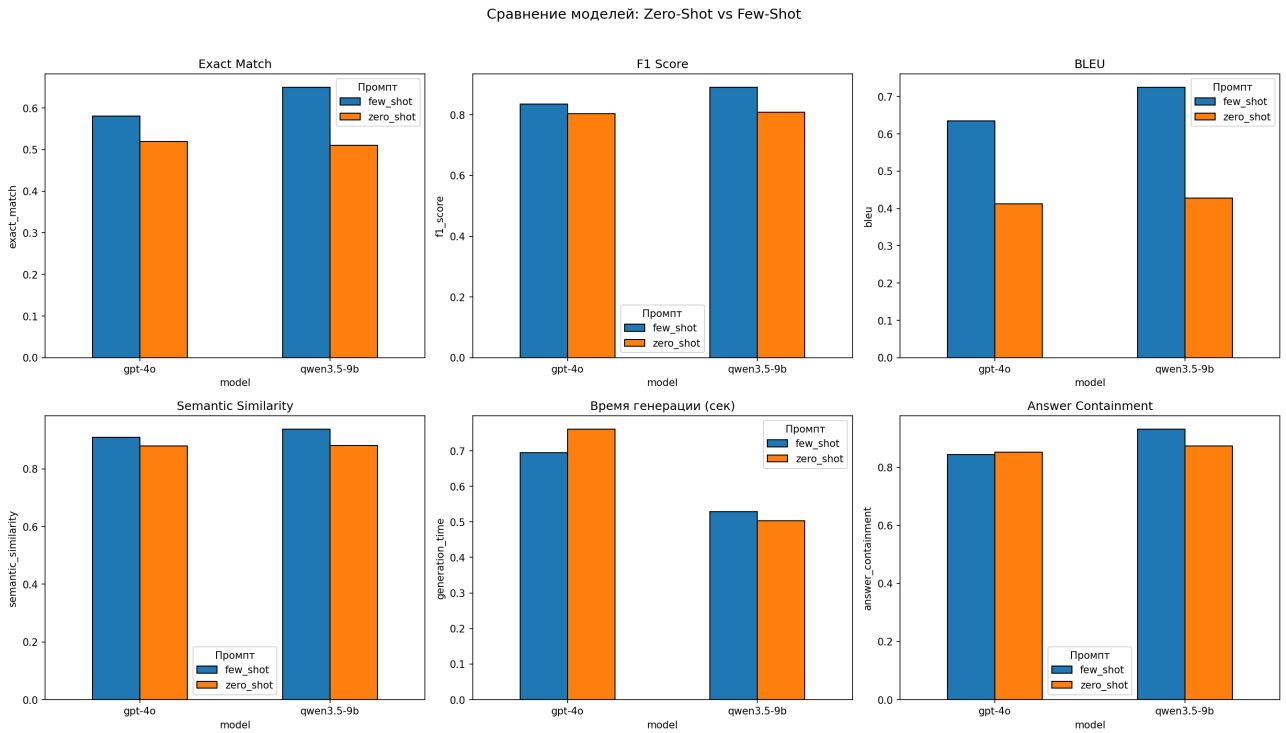

## 3. A/B-тест форматов промптов

| Формат | Qwen F1 | GPT-4o F1 | Qwen EM | GPT-4o EM |
|---|---|---|---|---|
| Baseline (текст) | 0.814 | 0.813 | 0.52 | 0.53 |
| Format A (XML) | 0.822 | 0.808 | 0.53 | 0.52 |
| Format B (инстр.) | 0.879 | 0.857 | 0.60 | 0.56 |

Инструкция-стиль (Format B) — лучший формат: Qwen F1=0.88 (+0.07 vs baseline), GPT-4o F1=0.86 (+0.05). XML-теги не дают значимого улучшения. Явная формулировка задачи эффективнее формальной структуры.

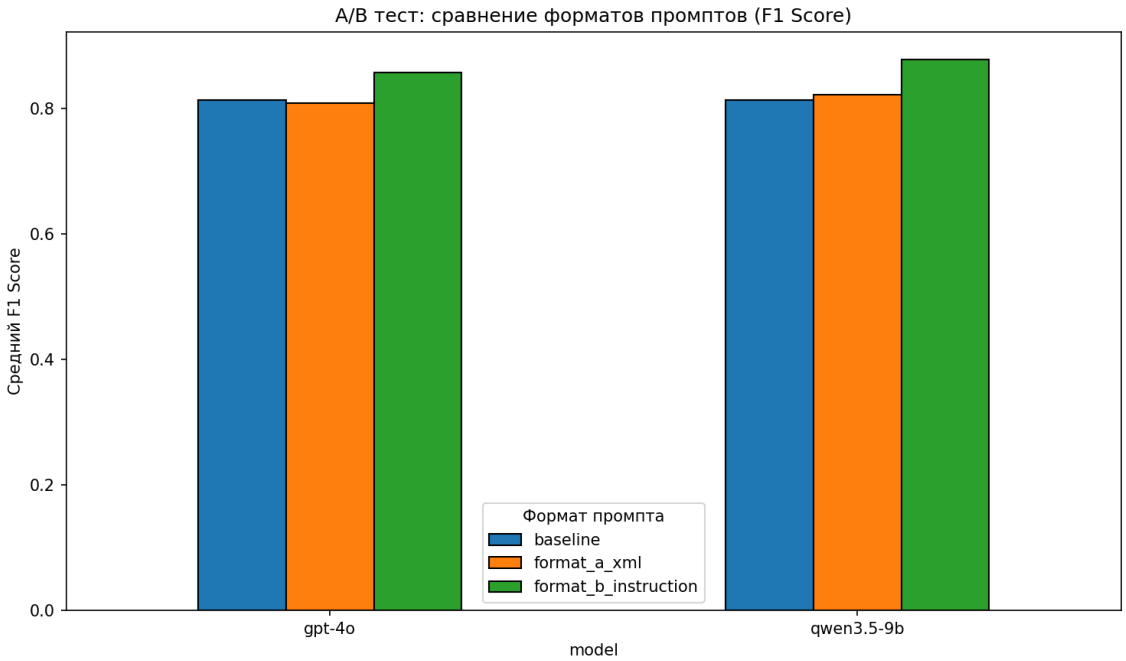


## 4. Влияние температуры

| Temperature | Qwen F1 | GPT-4o F1 | Qwen EM | GPT-4o EM |
|---|---|---|---|---|
| 0.0 | 0.808 | 0.789 | 0.51 | 0.49 |
| 0.3 | 0.793 | 0.803 | 0.49 | 0.50 |
| 0.7 | 0.783 | 0.791 | 0.51 | 0.49 |
| 1.0 | 0.781 | 0.779 | 0.49 | 0.44 |

Обе модели оптимальны при temperature 0.0–0.3. Повышение до 1.0 снижает F1 на ~0.02–0.03. Эффект монотонный — для extractive QA стохастичность генерации вредна.

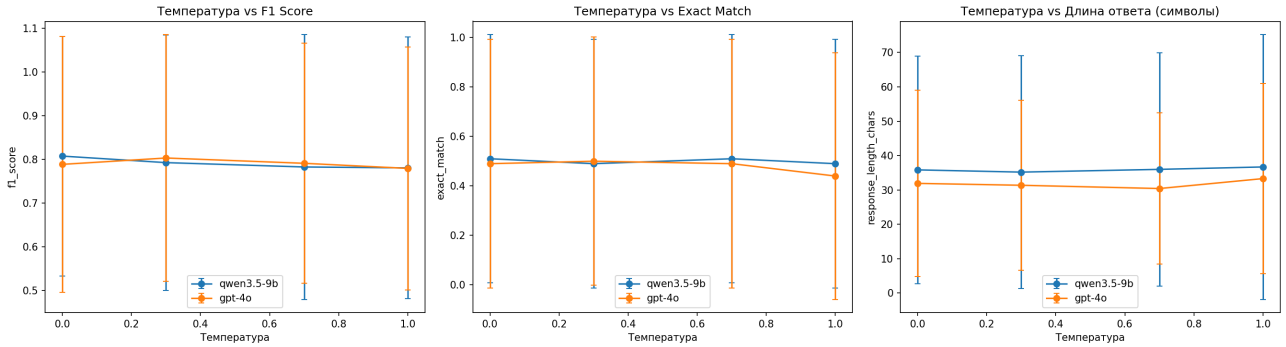
Температура vs F1 Score
f1_score
Температура
qwen3.5-9b
gpt-4o
Температура vs Exact Match
exact_match
Температура
qwen3.5-9b
gpt-4o
Температура vs Длина ответа (символы)
response_length_chars
Температура
qwen3.5-9b
gpt-4o

## 5. Влияние длины контекста

Контексты разбиты на 4 квартиля по длине. Наблюдается слабая отрицательная корреляция: на длинных контекстах F1 снижается. Эффект невелик и сопоставим для обеих моделей.

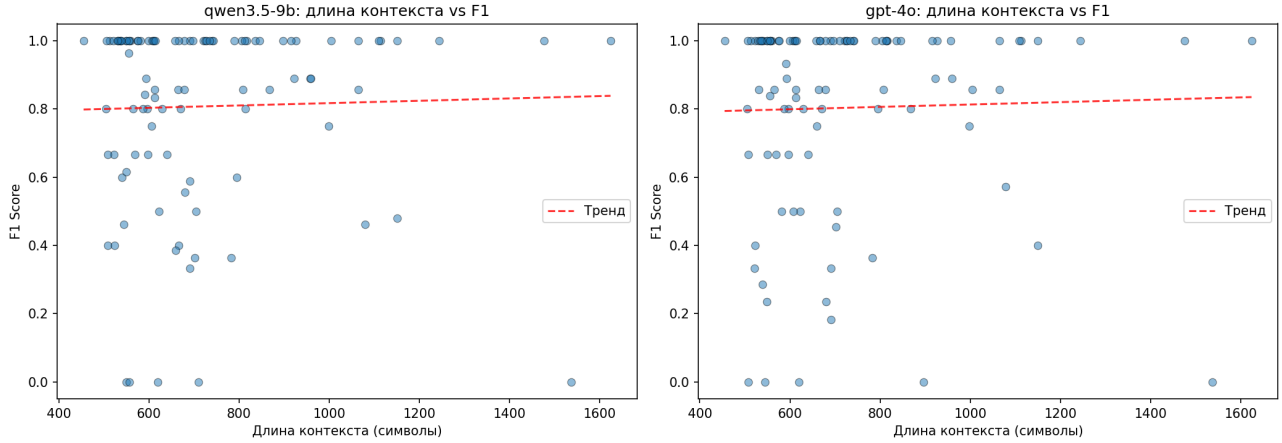


## 6. Анализ ошибок

| Тип ошибки | Qwen 3.5 9B | GPT-4o |
|---|---|---|
| correct | 51% | 52% |
| partial_overlap | 29% | 33% |
| verbose | 11% | 8% |
| completely_wrong | 5% | 5% |
| incomplete | 4% | 2% |

Распределения ошибок схожи. Qwen чаще выдаёт verbose-ответы (11% vs 8%), GPT-4o чаще partial_overlap (33% vs 29%). Полностью неверные ответы редки (~5%) — основная проблема в формулировке, а не в понимании.

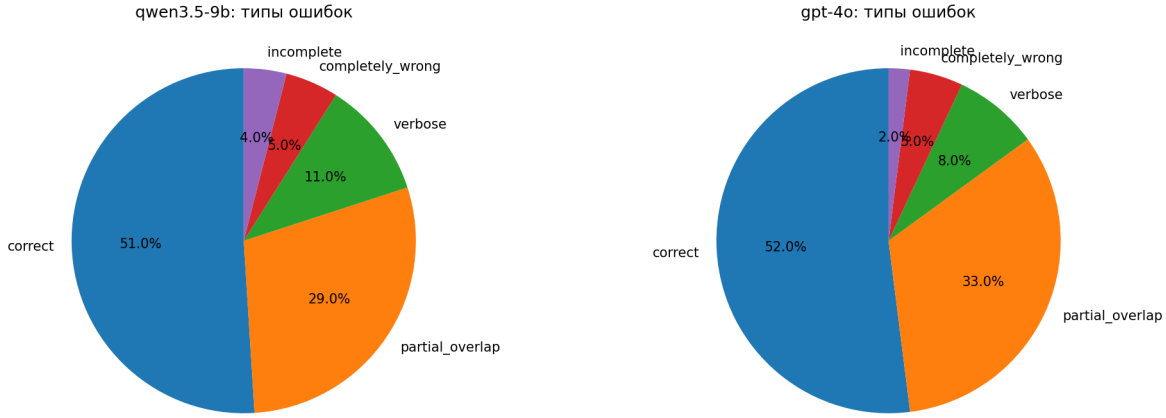

## 7. Статистическая значимость (бонус)

| Тест | Результат | Значимо (p<0.05)? |
|---|---|---|
| Wilcoxon signed-rank | p = 0.73 | Нет |
| Paired t-test | p = 0.87 | Нет |
| Bootstrap 95% CI | CI содержит 0 | Нет |

Три независимых теста подтверждают: разница между Qwen 3.5 9B и GPT-4o на zero-shot QA статистически не значима. Модели эквивалентны на данной задаче и выборке.

## 8. Информативность метрик

| Метрика | Оценка | Комментарий |
|---|---|---|
| F1 Score | Основная | Лучшая дифференциация качества |
| Sem. Similarity | Дополнит. | Полезна, но слабо дифференцирует |
| Ans. Containment | Дополнит. | Ловит verbose-ответы |
| Exact Match | Ограниченная | Слишком бинарная |
| BLEU | Низкая | Не подходит для коротких ответов |

## 9. Выводы и рекомендации

1. Qwen 3.5 9B (Q4_K_M) и GPT-4o эквивалентны на extractive QA по SberQuAD. Локальная модель не уступает коммерческому API при меньших затратах и латентности.

2. Оптимальная конфигурация: few-shot промптинг + инструкция-стиль + temperature = 0. Это даёт F1 до 0.89 (Qwen) и 0.86 (GPT-4o).

3. Формат промпта существенно влияет на результат (+0.07 F1). Температура влияет слабо (–0.03 F1 при temperature 1.0). Длина контекста — слабо отрицательная корреляция с F1.

4. Для оценки QA рекомендуется F1 Score как основная метрика, дополненная Semantic Similarity и Answer Containment.

### Ограничения

• Выборка 100 примеров достаточна для грубого сравнения, но не для выявления тонких различий.
• Время генерации GPT-4o включает сетевую задержку.
• Qwen в квантизации Q4_K_M — полная модель может показать результаты выше.